



Sound based client model

Modeling client types with emotion detection and context analyzer.

Or Elazar
Nadav Schneider



הקדמה

הצבנו לנו כמטרה ליצור אפליקציה שבאמצעות זיהוי קולי תצליח למדל סוגי לקוחות שונים בסביבה של שיחות טלפוניות לשירות לקוחות.

האפשרות למדל לקוח באמצעות אלגוריתמים מבוססי זיהוי קולי יאפשר טיפול נכון ומתאים יותר לכל לקוח עם טווח טעויות קטן יותר מאשר התבססות על תחושותיו האישיות של נותן השירות, ויאפשר לגורמים המקצועיים להגדיר בצורה אחידה, עפ"י תבניות מוסכמות, לאיזה קבוצה כל לקוח משתייך ואיזה טיפול כל לקוח צריך לקבל.



מוטיבציה

שאלה זו עניינה אותנו כיוון שכסטודנטים למדעי המחשב אנו מתעסקים הרבה באיך לכמת ולפתור בעיות יומיות באמצעות מתמטיקה ואלגוריתמים, ונחשפנו לא פעם לעובדה שגם להתנהגויות ותגובות אנושיות יש תבניות שחוזרות על עצמן ברוב האוכלוסיה (אנחנו לא כאלה פתיתי שלג מיוחדים מסתבר) ורצינו לנסות ולזהות את התבניות האלו ע"י זיהוי קולי.



שאלת המחקר

האם אפשר למדל סוגי לקוחות, למודלים קבועים מראש, ומה השימושים והאפשריים למודל כזה בשירותי לקוחות (CALL CENTERS) אשר ייעלו וישפרו את תפוקתם.



אתגרים

- לזהות רגשות עפ"י איך שלקוח אומר את הדברים (מודל אקוסטי)
- לזהות רגשות עפ"י מה שהלקוח אומר (קונטקסט).
- להצליב ולכמת את הנתונים שציונו לעיל לכדי מודל מספרי אשר ייצג כל לקוח.



שלבי העבודה

שלב א': איסוף המידע

- אבחון הבעיה
- מחקר ואיסוף נתונים על הבעיה והאתגרים העומדים בפנינו בדרך לפתרונה.
- חיפוש שיטות שונות לפתרון הבעיות.
- בדיקות ראשוניות של השיטות השונות ובחירת הכלים המתאימים ביותר להתמודדות עם הבעיה.



שלב II : מודלים ראשוניים

- איסוף מאגר נתונים לבניית מודל למידת מכונה
- יצירת מודל לזיהוי רגשות מבוסס מאפיינים אקוסטים
- מימוש STT
- מימוש של זיהוי רגשות מטקסט (לפי קונטקסט)



שלב III : מימוש המודל הסופי

- חיבור וסנכרון המודלים השונים שמימשנו בשלב הקודם
- מימוש של שיטת מידול הלקוחות בהתבסס על המודלים הקיימים
- מימוש האפליקציה הראשונית המזהה מאבחנת וממדלת שיחות של לקוחות עפ"י ניתוח הקונטקסט ומאפיינים האקוסטיים.



שלב IV: בדיקות ותיקונים אחרונים

- הרצת בדיקות על האפליקציה עם שיחות שירות לקוחות
- ניתוח הממצאים
- הסקת מסקנות
- תיקונים והתאמות נדרשות למודלים



ארכיטקטורה

האפליקציה תשב על הקו ותאזין רק לצד הלקוח.

עבור כל מקטע בו הלקוח דיבר (בין שקט לשקט) המקטע יועבר לעיבוד

המקטע ישלח למודל זיהוי הרגשות ע"י מאפיינים אקוסטיים, המודל ינתח את המקטע ויחזיר ערך מספרי (0 או 1 או -1)

במקביל המקטע ישלח למודל זיהוי הרגש עפ"י התוכן, המודל ינתח את המקטע וגם כן יחזיר ערך מספרי (0 או 1 או -1)

האפליקציה תעבד את כל הקלטים ותכמת אותם לסקאלה בין 5- ל- 5 (כשאר מינוס 5 לקוח מאד לא מרוצה, 5 : לקוח מרוצה מאד)

התוצאה תיכנס למאגר מידע ותשוקלל עם המידע הקיים על הלקוח (במידה ויש כזה)

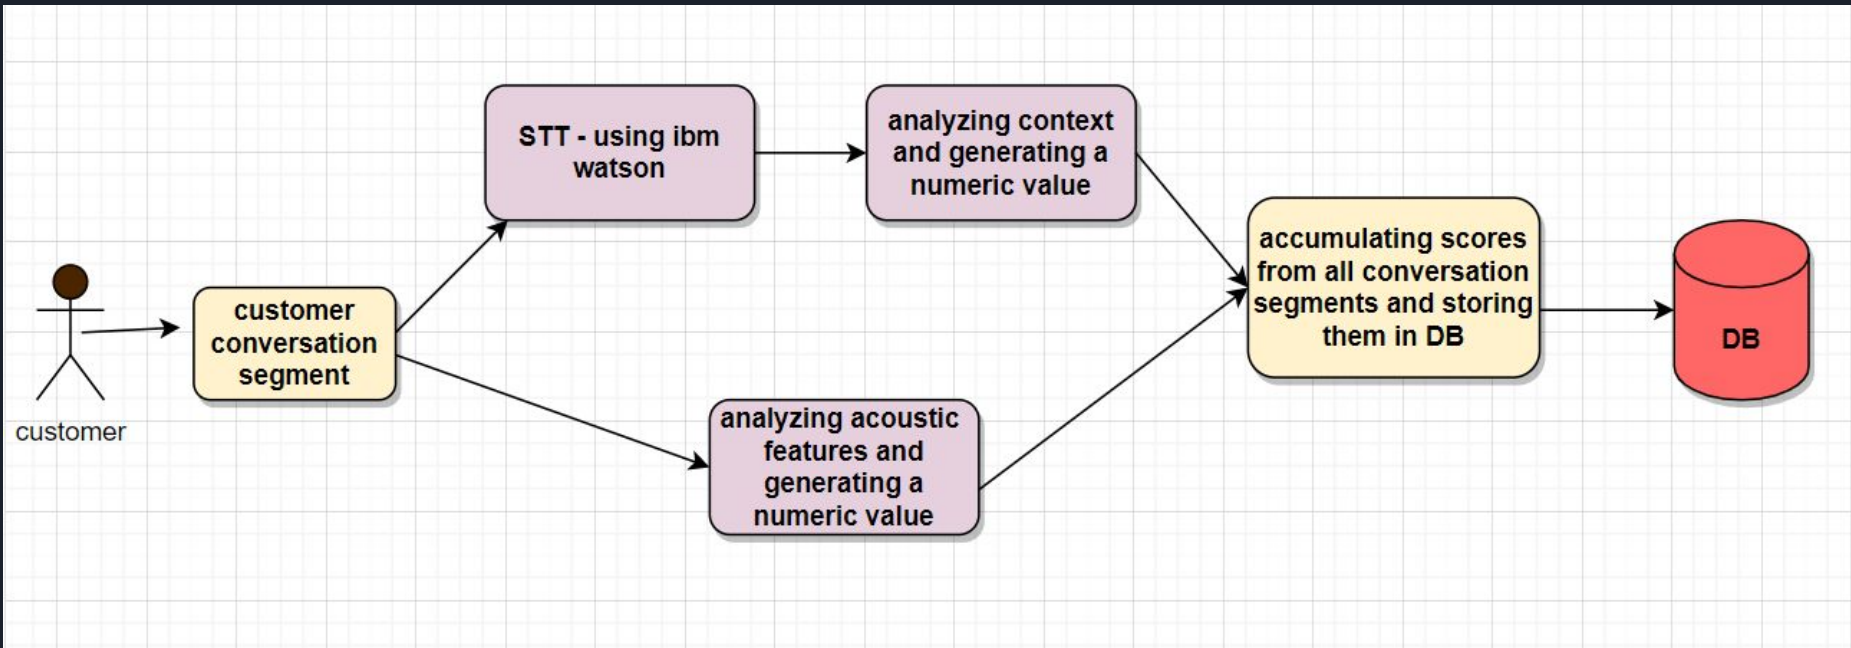


פונקציונליות המערכת

המערכת תדע למדל לקוחות ע"פ שביעות רצונם, תשמור את המידע המתקבל מהשיחה ותשקלל אותו המידע הקודם הקיים במערכת על הלקוח. כך יתאפשר לזהות מגמות שיפור או הרעה במצבו של הלקוח, ולקבל מידע מקדים על כל לקוח בטרם השיחה איתו (במידה ונמדדה בעבר לפחות שיחה אחת עם אותו לקוח).

כיוון שכל מקטע בשיחה מנותח בנפרד, המערכת תוכל לתת אינדיקציה בזמן אמת על מידת שביעות רצונו של הלקוח, אמנם התוצאה הסופית תוכל להתקבל רק לאחר שקלול תוצאות כל המקטעים, אך נוכל להפיק מדד חלקי בזמן אמת.

Application flow





תוכנות וכלים שהשתמשנו בפרויקט

Praat

השתמשנו ב PRAAT כדי לערוך את קבצי האודיו עליהם ביצענו את הבדיקות.

- הפרדת צד הלקוח מצד נותן השירות, חלוקת השיחה למקטעים נפרדים.
- התאמת מאפייני קובץ הקול לעיבוד ע"י מודל זיהוי רגשות באמצעות מאפיינים אקוסטיים (המודל עובד על קבצי wav עם 16000 sample rate ו mono channel).



:Watson STT

השתמשנו במנוע watson של IBM כדי להמיר קטעי קול של הלקוח לטקסט, כדי שנוכל לאחר מכן לנתח את התוכן ולהסיק ממנו הרגש המועבר ע"י הלקוח.

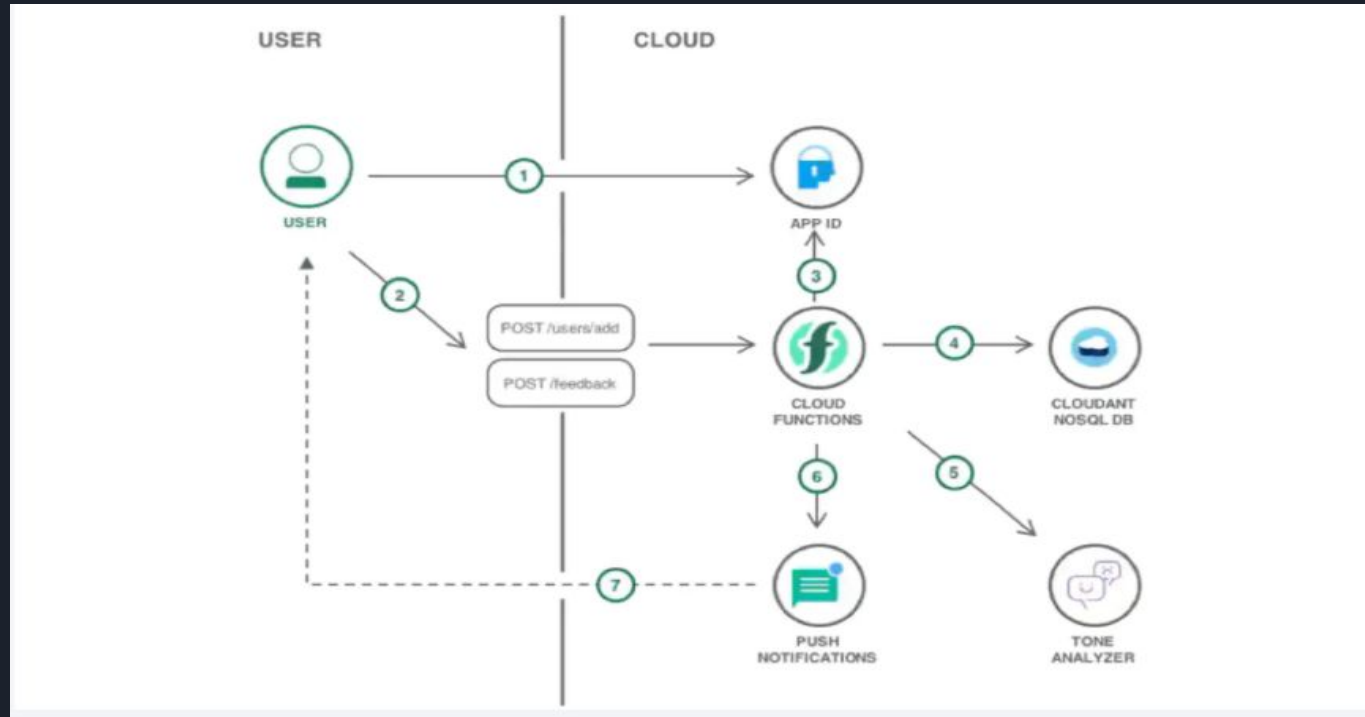
בחרנו ב-Watson STT כיוון שהוא קל לאימפלמנטציה, הוא מניב תוצאות טובות ברמת אמינות ודיוק גבוהה במהירות טובה.



Watson Tone Analyzer

לאחר שהמרנו את דיבור הלקוח לטקסט, אנו משתמשים ב watson tone analyzer כדי לנתח את הרגש המשתמע מתוך השיחה, ובאמצעות המידע המתקבל מתהליך זה אנחנו מייצרים פלט המייצג את הרגש.

Watson Tone Analyzer Flow



סיפריית פייטון לבניית מודלים למידת מכונה.

השתמשנו ב sklearn כדי לבנות את מודל למידת המכונה המזהה רגשות ע"י שליפת מאפיינים אקוסטיים המודל נבנה באמצעות למידה מונחית.

Sklearn supervised learning Flow





librosa

באמצעות librosa שלפנו את המאפיינים האקוסטיים של קטעי הקול, הן ליצירת מודל למידת מכונה לזיהוי רגשות, והן לניתוח המאפיינים באמצעות מודל זה כדי לקבל תוצאות.



מקורות מידע

<https://ieeexplore.ieee.org/abstract/document/8869008>

-Ahmed **Recognizing Language and Emotional Tone from Music Lyrics using IBM Watson Tone Analyzer**
Al Marouf Rafayet Hossain Md. Rahmatul Kabir Rasel Sarker Bishwajeet Pandey Shah Md. Tanvir Siddiquee
Human Computer Interaction Research Lab (HCI RL) Department of Computer Science and Engineering
Daffodil International University (DIU) Dhaka, Bangladesh marouf.cse@diu.edu.bd, rafayet3994@diu.edu.bd,
kabir37323@diu.edu.bd Gyancity Research Lab Motihari, India gyancity@gyancity.com Department of CSE
Daffodil International University (DIU) Dhaka, Bangladesh tanvir.cse@diu.edu.bd



Recognizing Language and Emotional Tone from Music Lyrics using IBM Watson Tone Analyzer

המאמר לעיל עוסק בניסיון לזהות רגשות בשירים עפ"י מילות השיר.

שיטת המחקר: איסוף dataset של מילות שירים מהאינטרנט וקיטלוגם לשירים עם מילים שמחות, עצובות, כועסות וכד'. ניתוח רגשות המופיעים במילים ע"י Watson tone analyzer ובדיקת אחוזי ההצלחה. עפ"י הממצאים אנו רואים שאחוזי ההצלחה לזיהוי רגשות מטקסט היו גבוהים מאד (מעל 75 אחוז לכל סוגי הרגשות).

המאמר רלוונטי לנו כיוון שהוא מתעסק בשאלה כיצד ניתן לזהות רגשות כאשר יש חוסר התאמה בין הפיצ'רים האקוסטיים ותוכן הדיבור, הרי בשיר אי אפשר להתבסס על פיצ'רים אקוסטיים כיוון שהם מונעים בעיקר משיקולים מוזיקליים ואינם פיצ'רים אקוסטיים התואמים דיבור טבעי.

התעמתנו עם השאלה כיצד נוכל לזהות לקוח לא מרוצה בסיטואציות בהן יש חוסר התאמה בין הדרך בה נאמרים הדברים ותוכן הדברים (ציניות לדוגמא), מאמר זה מאשש את התאוריה שלנו שנוכל להסתמך על Watson tone analyzer ככלי נוסף באמצעותו נוכל לאבחן את סוג הלקוח בצורה טובה יותר.



<https://ieeexplore.ieee.org/abstract/document/9394292>

Real-time Emotion Recognition for Sales - Si-Ahmed Naas Dept.
Communication and Networking Aalto University
firstname.lastname@aalto.fi Stephan Sigg Dept. Communication and
Networking Aalto University firstname.lastname@aalto.f



Real-time Emotion Recognition for Sales

מאמר זה עוסק בזיהוי רגשות של לקוחות בשיחות שיווק ומכירה ע"י ניתוח קול הלקוח בזמן אמת, וכיצד ניתן בעזרת זיהוי מהיר של רגשות לשפר את איכות השירות. למשל, חוסר שביעות רצון דורש תגובה, בעוד שרוגע יכול להיות ניטרלי.

המאמר רלוונטי לנו כיוון שהוא מציע שיטות שונות שבעזרתן אפשר לממש את זיהוי הרגשות, ומתייחס לדרכים בהן אפשר להשתמש בזיהוי רגשות לשיפור השירות.

מאמר זה מראה שתגובות ורגשות הלקוח יכולות להצביע על הצורך בהתאמות בשירות. המאמר מציע שיטה שבה כל רגש מקבל ציון מספרי, כאשר ציון 0 מייצג רגש שעפ"י ממצאם נחשב ניטרלי בשירות לקוחות, מינוס אחד – רגש שלילי, ו-1 רגש חיובי. אנו נתבסס בפרוייקט שלנו על שיטת הניקוד הזו כדי להעריך את מידת שביעות הרצון של הלקוח ובניית המודל המאפיין כל לקוח



IBM - api docs

השתמשנו בתיעוד של של IBM-WATSON-STT.

ובתיעוד של IBM-WATSON-TONE ANALYZER.

למדנו כיצד להשתמש בכלים אלו ולהפיק את התוצאות הרצויות לנו באמצעות התיעוד של IBM.

<https://cloud.ibm.com/apidocs/speech-to-text>

<https://cloud.ibm.com/apidocs/tone-analyzer>



מאגרי מידע

RAVDESS dataset - דאטה סט של כאלף הקלטות של שחקנים.

הדאטה סט מכיל מספר משפטים שונים, כל משפט נאמר ע"י כל שחקן (24 שחקנים שונים) במספר צורות שונות (כועס, שמח, עצוב וכד'...)

כיוון שאותו משפט נאמר ע"י אותו שחקן מספר פעמים בצורה שונה, ניתן לבודד את המאפיינים האקוסטיים שקשורים לרגש בצורה יחסית סטירילית ולא מושפעת מקונטקסט שונה, חתימת קול שונה וכד'. לכן השתמשנו בדאטה סט הנ"ל כדי לאמן את מודל למידת המכונה.

[/https://smartlaboratory.org/ravdess](https://smartlaboratory.org/ravdess)

האפליקציה

מודל למידת

המכונה:

שליפת מאפיינים

אקוסטיים מקובץ קול.

```
def extract_feature(file_name, **kwargs):
    """
    Extract feature from audio file `file_name`
    Features supported:
    - MFCC (mfcc)
    - Chroma (chroma)
    - MEL Spectrogram Frequency (mel)
    - Contrast (contrast)
    - Tonnetz (tonnetz)

    e.g:
    `features = extract_feature(path, mel=True, mfcc=True)`
    """
    mfcc = kwargs.get("mfcc")
    chroma = kwargs.get("chroma")
    mel = kwargs.get("mel")
    contrast = kwargs.get("contrast")
    tonnetz = kwargs.get("tonnetz")
    with soundfile.SoundFile(file_name) as sound_file:
        X = sound_file.read(dtype="float32")
        sample_rate = sound_file.samplerate
        if chroma or contrast:
            stft = np.abs(librosa.stft(X))
            result = np.array([])
            if mfcc:
                mfccs = np.mean(librosa.feature.mfcc(y=X, sr=sample_rate, n_mfcc=40).T, axis=0)
                result = np.hstack((result, mfccs))
            if chroma:
                chroma = np.mean(librosa.feature.chroma_stft(S=stft, sr=sample_rate).T, axis=0)
                result = np.hstack((result, chroma))
            if mel:
                mel = np.mean(librosa.feature.melspectrogram(X, sr=sample_rate).T, axis=0)
                result = np.hstack((result, mel))
            if contrast:
                contrast = np.mean(librosa.feature.spectral_contrast(S=stft, sr=sample_rate).T, axis=0)
                result = np.hstack((result, contrast))
            if tonnetz:
                tonnetz = np.mean(librosa.feature.tonnetz(y=librosa.effects.harmonic(X), sr=sample_rate).T, axis=0)
                result = np.hstack((result, tonnetz))
    return result
```

אימון ויצירת המודל

```
model = MLPClassifier(**model_params)

# train the model
print("[*] Training the model...")
model.fit(X_train, y_train)

# predict 25% of data to measure how good we are
y_pred = model.predict(X_test)

# calculate the accuracy
accuracy = accuracy_score(y_true=y_test, y_pred=y_pred)

print("Accuracy: {:.2f}%".format(accuracy*100))

# now we save the model
# make result directory if doesn't exist yet
if not os.path.isdir("result"):
    os.mkdir("result")

pickle.dump(model, open("result/mlp_classifier.model", "wb"))
```

מודל רגשות

מטקסט

הפיכת הקול לטקסט

```
def analyze_tone(filename):  
    with open(filename, 'rb') as f:  
        STT_result = stt.recognize(audio=f, content_type='audio/wav', model='en-US_NarrowbandModel').get_result()  
  
    STT_confidence = STT_result['results'][0]['alternatives'][0]['confidence']  
    STT_transcript = STT_result['results'][0]['alternatives'][0]['transcript']  
    print(STT_transcript)  
    print('stt confidence level:', STT_confidence)  
  
    TA_result = ta.tone(STT_transcript).get_result() הוצאת רגשות מהטקסט  
  
    if(TA_result['document_tone']['tones']):  
        TA_emotion = TA_result['document_tone']['tones'][0]['tone_id']  
        print(TA_emotion)  
        if(STT_confidence > 0.46):  
            if(TA_emotion == 'joy'):  
                return 1  
            if(TA_emotion == 'anger'):  
                return -1  
            if(TA_emotion == 'sadness'):  
                return -1  
            return 0  
        else:  
            return 0
```

```

(soundvenv) C:\school\soundproject\emotiondedection>python app.py zootopia 5 1
samples\zootopia01.wav
result: happy
but it's nice to see
stt confidence level: 0.8
joy
1
1
samples\zootopia02.wav
result: sad
but it's nice to see
stt confidence level: 0.81
joy
1
-1
samples\zootopia03.wav
result: angry
Hey flash I'd love you to meet my friend I think he has C. P. how are
stt confidence level: 0.74
joy
1
-1
samples\zootopia04.wav
result: angry
a blast one of your a joke
stt confidence level: 0.58
0
-1
samples\zootopia05.wav
result: angry
I love you I oh yes
stt confidence level: 0.69
joy
1
-1
total score: 1
last score: -2.15
total score: -0.475

(soundvenv) C:\school\soundproject\emotiondedection>

```

דוגמאות ריצה

A sloth's great customer service (Zootopia)

פורמט הפלט:

- שם הקובץ
- הרגש שהתקבל מניתוח מאפיינים
- אקוסטיים
- המשפט המתומלל
- רמת ביטחון של תרגום המשפט
- הרגש ההתקבל מניתוח הטקסט
- הציון שהתקבל מניתוח השמע
- הציון שהתקבל הטקסט
- ❖ הציון הסופי שהתקבל מהשיחה
- ❖ הציון הקודם של הלקוח השמור
- DB
- ❖ הציון המשוקלל החדש

<https://www.youtube.com/watch?v=4T2GmGSNvaM>

```
(soundvenv) C:\school\soundproject\emotiondedection>python app.py Seinfeld 4 3
```

```
samples\Seinfeld01.wav
```

```
result: angry
```

```
I understand I made a reservation do you have my reservation yeah
```

```
stt confidence level: 0.92
```

```
0
```

```
-1
```

```
samples\Seinfeld02.wav
```

```
result: angry
```

```
but the reservation keeps the car here
```

```
stt confidence level: 0.95
```

```
0
```

```
-1
```

```
samples\Seinfeld03.wav
```

```
result: angry
```

```
I don't think you do
```

```
stt confidence level: 0.95
```

```
analytical
```

```
0
```

```
-1
```

```
samples\Seinfeld04.wav
```

```
result: angry
```

```
you did I have a car
```

```
stt confidence level: 0.69
```

```
0
```

```
-1
```

```
total score: -4
```

```
(soundvenv) C:\school\soundproject\emotiondedection>
```

```
(soundvenv) C:\school\soundproject\emotiondedection>python app.py badcsscrew 6 2
samples\badcsscrew01.wav
result: angry
you know what I'm a little annoyed I keep coming in here and you guys keep **** up
stt confidence level: 0.89
anger
-1
-1
samples\badcsscrew02.wav
result: angry
I bought this drill two weeks ago I go home use it it doesn't work
stt confidence level: 0.85
sadness
-1
-1
samples\badcsscrew03.wav
result: angry
now I spend a lot of time and money driving back and forth just to have you guys come up over and over and I've had
stt confidence level: 0.84
tentative
0
-1
samples\badcsscrew04.wav
result: angry
all I want all I want is to have a drill that works
stt confidence level: 0.77
sadness
-1
-1
samples\badcsscrew05.wav
result: calm
okay well I appreciate that
stt confidence level: 0.87
joy
1
0
samples\badcsscrew06.wav
result: angry
I spend a lot of time and money driving back and forth just to have you guys come up over and over
stt confidence level: 0.87
tentative
0
-1
total score: -5

(soundvenv) C:\school\soundproject\emotiondedection>
```

https://www.youtube.com/watch?v=T20hV4ynU7o&ab_channel=JMCTheDirector



מדדים ויעדים ואופן בדיקתם

מודל למידת מכונה:

יעדים : הצבנו לנו כיעד למודל למידת המכונה לזיהוי רגשות להגיע לרמת דיוק של מעל 75 אחוז על הקלטות השחקנים, וכ 60 אחוז בניתוח דיבור חופשי.

מדדים: מדדנו את אחוזי ההצלחה של מודל זיהוי הרגשות ע"י אימון המודל על 80% ממאגר המידע ובדיקתו על 20% ההקלטות הנותרות. אחוזי ההצלחה של המודל שלנו עומדים ביעד.

את הצלחת המודל על דיבור חופשי מדדנו על שיחות שירות לקוחות מסרטים וסדרות טלוויזיה שתיגנו מראש לקטגוריות (לקוח מרוצה/ לא מרוצה), בסיטואציות האלו רמת הדיוק של המודל היא אזור ה 50% ואינו עומד ביעד שהצבנו.



מודל זיהוי רגשות מטקסט:

יעדים:

רמת דיוק של מעל 85% בזיהוי דיבור והפיכתו לטקסט STT.

רמת דיוק של מעל 85% בזיהוי רגשות מטקסטים בהם ישנו שימוש מובהק וברור במילים המשקפות רגש מסויים, לדוגמא : "im very angry" - כעס

רמת דיוק של כ 60% בזיהוי רגשות בהם לא נעשה שימוש מובהק במילים המתארות רגש אלא הרגש משתמע מההקשר.

מדדים:

מדדנו את מנוע ה STT הן על הקלטות מבוקרות של שחקנים והן על דיבור חופשי ובשני המקרים רמת הדיוק הייתה גבוהה מאד. בהקלטות מבוקרות רמת דיוק עולה על 90 אחוז, ובהקלטות של דיבור חופשי גם כן ראינו תוצאות טובות, המנוע הצליח לתמלל את רוב הדיבור עד כדי פספוס של מילה במשפט.

כמו כן בדקנו בצורה דומה את זיהוי הרגש מטקסט, במקרה זה ראינו שהמודל מזהה בצורה טובה רגש של שמחה, אך מתקשה יותר לזהות כעס כשהוא לא מפורש.



האפליקציה הסופית:

הצבנו לנו כיעד ששיחה של לקוח לא מרוצה תייצר פלט שלילי (בין 5- ל 1-) ושיחה של לקוח מרוצה תייצר פלט חיובי (בין 1 ל 5), כאשר ציפינו לראות תוצאות סביב 0 לשיחות בהם מצבו של הלקוח אינו חד משמעי וברור.


הרצנו את האפליקציה על שיחות שירות הלקוחות בדיבור חופשי שאספנו מסרטים וסדרות שתייגנו לקטגוריות של לקוח מרוצה\לא מרוצה ובדקנו את הפלט המתקבל משיחות אלו.

מצאנו שבמקרים מסויימים תוצאות המודלים לא הייתה זהה לחלוטין, אך לא הייתה סתירה בין רגש שמח לכועס. כלומר לא תמיד קיבלנו תוצאה שלילית מלקוח כועס ותוצאה חיובית מלקוח מרוצה, אך לקוח מרוצה לא קיבל תוצאה שלילית ולהפך, אלא תוצאות ניטרליות.



מסקנות ותובנות

- נוכחנו לגלות שרגשות קיצוניים (דוגמת כעס, שמחה) ניתן לזהות בדיוק גבוהה וקלות יחסית, כאשר בן אדם משתמש במילים הנחשבות "כועסות" (או "שמחות") ובדיבור מאד רגשי קל לזהות ולאבחן זאת.
- לפי ממצאי הניסויים שלנו בשיטות זיהוי רגשות גילינו שרגשות שהם לא מאד קיצוניים קשה לאבחן בדיוק גבוה.
- השילוב בין ניתוח הצורה בה הדברים נאמרים ומה נאמר הוא הכרחי כדי לזהות בצורה טובה את הרגש המועבר בשיחה, בהרבה מקרים המודלים מפצים אחד על השני וכשאחד לא קורא נכון את הסיטואציה השני מאבחן אותה בצורה טובה.



- המאפיינים האקוסטיים של זיוף רגש הם הרבה יותר קיצוניים ולא מייצגים בצורה טובה מאפיינים אקוסטיים של רגש אמיתי, (קשה לזייף את המאפיינים האקוסטיים בדיבור רגשי בצורה מדויקת ותואמת למציאות).

- שמנו לב כי כדי להבין את ההקשר של השיחה בצורה מדויקת לא תמיד מספיק לנתח את צד הלקוח, כיוון שמתנהל דו שיח ישנם מקרים בהם הצד של נותן השירות מהותי והכרחי כדי להבין את ההקשר.

- שמנו לב שברוב המקרים אנשים לא מבטאים את הרגשות שלהם בצורה חד משמעית בדיבור שלהם, בן אדם כועס לא בהכרח ידבר בטונים תקיפים ויגיד מילים הנתפסות ככועסות, אלא רק באמצעות הבנה נרחבת של הסיטואציה וההקשר נדע להבחין כי הבן אדם כועס. הדיבור הטבעי מורכב מקשת הרבה יותר רחבה של רגשות וניואנסים. דבר זה מקשה על זיהוי חד משמעי של הכוונה מאחורי הדיבור באמצעות אלגוריתם אחיד.



מחשבות לעתיד

במהלך הפרוייקט מימשנו STT ניתוח רגש וניתוח הקשר מקטעי קול, הצלחנו לעשות זאת במהירות גבוהה מאד וכמעט מיידית וזה גרם לנו לחשוב על שימושים אפשריים למערכת כזאת בן אמת, היכולת לזהות את מצבו הרגשי של לקוח בזמן השיחה והשימושים האפשריים באמצעות יכולת זאת לנווט ולייעל שירות בזמן אמת בסביבות בו השירות מבוסס על שיחות טלפון.

חשבנו על האפשרות להרחיב את המודל ולהתאים אותו כדי שיוכל גם לנתח את צד נותן השירות ולא רק את צד הלקוח, באמצעות יכולת כזו נוכל למדוד את האם נותן השירות פונה ללקוחות בצורה טובה (לדוגמא נותן השירות מדבר בצורה חסרת סבלנות וגורם ללקוח להתעצבן, או ההפך, נותן שירות שיודע להרגיע לקוח כועס). בנוסף באמצעות מודל כזה נוכל להבין ולהסיק איך לקוחות מגיבים לנותני שירות שונים ולגישות שונות ולהתאים בצורה טובה יותר את צורת מתן השרות ו/או את נותן השירות בהתאם לכל לקוח.

כיוון שהאפליקציה שלנו שומרת במסד נתונים את הערך המספרי של כל לקוח לאחר כל שיחה, נוכל לעקוב אחר ההתפתחות של כל לקוח ולזהות ירידה/ עלייה בשביעות רצון לאחר שיחה מסויימת, באמצעות זה נוכל לנתח את תוכן השיחה (מי היה המטפל האם הוצעו מבצעים מסויימים תוך כמה זמן נפתרה הבעיה אם נפתרה וכו..) ולדעת להתאים נותני שירות או טיפול מסויים ללקוחות מסויימים.